AKADEMIA GÓRNICZO-HUTNICZA
IM. STANISŁAWA STASZICA W KRAKOWIE

Wydział Informatyki, Elektroniki i Telekomunikacji
Katedra Informatyki

PROJEKT INŻYNIERSKI

WERYFIKACJA AUTORSTWA Z WYKORZYSTANIEM REKURENCYJNYCH SIECI NEURONOWYCH

AUTHOR IDENTIFICATION WITH RECCURENT NEURAL NETWORKS

MARCIN RADZIO

KIERUNEK:
Informatyka

OPIEKUN:
dr inż. Marcin Kuta, AGH

Kraków 2017

Uprzedzony o odpowiedzialności karnej na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.): „Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystycznego wykonania albo publicznie zniekształca taki utwór, artystyczne wykonanie, fonogram, wideogram lub nadanie.”, a także uprzedzony o odpowiedzialności dyscyplinarnej na podstawie art. 211 ust. 1 ustawy z dnia 27 lipca 2005 r. Prawo o szkolnictwie wyższym (t.j. Dz. U. z 2012 r. poz. 572, z późn. zm.): „Za naruszenie przepisów obowiązujących w uczelni oraz za czyny uchybiające godności studenta student ponosi odpowiedzialność dyscyplinarną przed komisją dyscyplinarną albo przed sądem koleżeńskim samorządu studenckiego, zwanym dalej «sądem koleżeńskim».”, oświadczam, że niniejszą pracę dyplomową wykonałem(-am) osobiście, samodzielnie i że nie korzystałem(-am) ze źródeł innych niż wymienione w pracy.

. . . . . .

PODPIS

Spis treści

1 Cel prac i wizja produktu **4**
1.1 Charakterystyka problemu 4
1.2 Motywacja projektu 4
1.3 Wizja produktu 4
1.4 Analiza ryzyka 4
1.4.1 Czas testowania 4
1.4.2 Nieznajomość języka 5
1.4.3 Nowa technologia 5
1.4.4 Wymagający temat 5
1.5 Studium wykonalności 5

2 Zakres funkcjonalności **5**
2.1 Wymagania funkcjonalne 5
2.2 Wymagania niefunkcjonalne 6

3 Wybrane aspekty realizacji **6**
3.1 Multi-headed deep RNN 6
3.2 Batch danych 7
3.3 Preprocessing 7

4 Organizacja pracy **8**
4.1 Metodyka 8
4.2 Postępy 8

5 Wyniki projektu **9**
5.1 Osiągnięcia 9
5.2 Wyniki eksperymentów 9
5.3 Propozycje dalszego rozwoju 9

6 Dodatki **9**
6.1 Spotkania z opiekunem 9
6.2 Spotkania z prowadzącym pracownię projektową 10

1. Cel prac i wizja produktu

1.1. Charakterystyka problemu

Zadanie weryfikacji autorstwa polega na zdeterminowaniu, czy autor małego zbioru znanych tekstów jest także autorem pewnego kwestionowanego tekstu. Zadanie to zostało zdefiniowane w ten sposób w konkursie PAN 2015, a jednym z zaproponowanych rozwiązań było wykorzystanie wielogłowych, rekurencyjnych sieci neuronowych, autorstwa Douglasa Bagnalla. Rozwiązanie to okazało się szczególnie efektywne w warunkach konkursu, choć w praktyce zastosowanie takiego podejścia może się nie sprawdzić.

1.2. Motywacja projektu

W ostatnich latach mogliśmy doświadczyć ogromnego postępu w dziedzinie uczenia maszynowego, a przede wszystkim w świecie sieci neuronowych. Powstało wiele zaawansowanych frameworków (Torch, Theano, TensorFlow), które pozwoliły na łatwe tworzenie nawet skomplikowanych sieci, wciąż zapewniając szybką naukę i kontrolę nad jej przebiegiem. Wraz z nimi pojawiły się biblioteki dedykowane dla pewnych zastosowań, jak 'torch-rnn', który daje możliwość uczenia rekurencyjnych sieci neuronowych dla znakowego modelu językowego (character level language model RNN). Jednakże wciąż brakuje bibliotek, które pozwoliłyby na trenowanie sieci dla zadania weryfikacji autorstwa tekstu pisanego. Otóż przedmiotem tej pracy jest napisanie takiej właśnie biblioteki.

1.3. Wizja produktu

Najważniejszym założeniem projektu jest dostarczenie biblioteki, która pozwoli na konfigurowalne tworzenie głębokich sieci typu RNN, trening, preprocessing danych wejściowych, persystencja wytrenowanych modeli oraz ich dalsze testowanie. Zakłada się, że system powinien wspierać naukę w co najmniej czterech językach: angielskim, greckim, hiszpańskim i holenderskim. Wyżej wspomniana konfigurowalność powinna pozwalać na tworzenie dowolnych sieci parametryzowanych wartościami: głębokość sieci, wymiar wektorów wejściowych, ilość neuronów w warstwach ukrytych, wielkość batchów, itd. Ważna jest też możliwość wizualizacji modelu, np. poprzez generację grafu obrazującego strukturę sieci. Preprocessing powinien minimalizować wielkość alfabetu wejściowego bez utraty charakterystyk tekstu.

1.4. Analiza ryzyka

1.4.1. Czas testowania

Produkcja takiej biblioteki wiąże się z nieustannym testowaniem jakości generowanych sieci, co na ogół jest czasochłonne. Trening sieć nawet niedużych rozmiarów pochłania znaczną ilość zasobów procesora oraz wcześniej wspomnianego czasu, który może dochodzić nawet do kilkunastu godzin. W celu minimalizacj zagrożeń z tej strony wykorzystałem moc obliczeniową klastra Prometheus, co pozwoliło na testy bez obciążania własnego sprzętu.

1.4.2. Nieznajomość języka

Język Lua nie był mi wcześniej znany w praktyce, ale spędzenie czasu na nauce jego składni i zasad nie był czasem straconym, gdyż język jest bardzo ciekawy i w połączeniu z frameworkiem Torch jest niebywale efektywny w dziedzinie uczenia maszynowego i obliczeń naukowych.

1.4.3. Nowa technologia

Jednym z większych wyzwań projektu było nauczenie się korzystania z ważniejszych bibliotek, które framework Torch udostępnia. Ta technologia również nie była mi wcześniej znana, ale widzę mnóstwo potencjalnych powodów, aby używać go w przyszłości.

1.4.4. Wymagający temat

Dość długi czas spędziłem próbując zrozumieć działanie RNN. Z pomocą przyszedł mi Alfredo Canzani (jeden z twórców Torcha) ze swoją serią filmów Youtube na temat mechaniki sieci neuronowych, w szczególności tych rekurencyjnych. Studium kodu źródłowego char-rnn Anthony'ego Karpathy'ego także dała mi sporo doświadczenia oraz pomysł na realizację końcowego produktu.

1.5. Studium wykonalności

Dzięki wykorzystaniu zasobów superkomputera Prometheus większość zagrożeń związanych z brakiem zasobów pamięciowych czy czasu procesora zostanie rozwiązane i w większym stopniu będę mógł skupić się na planowaniu i rozwijaniu projektu. Korzyściami wynikającymi z braku zespołu jest fakt, że czas nie jest tracony na konsultacje pomiędzy członkami oraz kod wykazuje większą spójność, jednakże projekt powstaje wolniej. Podsumowując, projekt ma duże szanse powodzenia, choć jego użyteczność może być ograniczona.

2. Zakres funkcjonalności

2.1. Wymagania funkcjonalne

- udostępnienie mechanizmu przetwożania tekstów wejściowych w celu minimalizacji alfabetu języka
- zapewnienie eksportu danych do postaci binarnej, dającej możliwość wielokrotnego wczytania i wykorzystania ich bez ponownego preprocessingu
- możliwość zdefiniowania i stworzenia dowolnego modelu określonego przez parametry:
  - maksymalna ilość różnych autorów tekstów w modelu
  - wielkość warstwy ukrytej
  - poziom głębokości sieci
- parametryzowanie trenowania sieci poprzez:

  - wielkość batchów danych
  - współczynnik uczenia
  - tempo zmniejszania się współczynnika uczenia
  - maksymalną ilość epok
  - długość sekwencji znaków, na której uczony będzie model
- zapewnienie czytelnych logów, w trakcie działania programu, przedstawiających postęp uczenia oraz aktualny błąd

2.2. Wymagania niefunkcjonalne

- realizacja projektu w ramach pracy inżynierskiej
- bazowanie na dokumentach Douglasa Bagnalla na temat wielogłowych RNN i wykorzystanie napisanego przez niego modułu preprocessingu tekstu
- wykorzystanie języka Lua oraz frameworka Torch
- trenowanie i testowanie sieci na zbiorach PAN 2014 dla zadania weryfikacji autorstwa
- użycie systemu kontroli wersji Git

3. Wybrane aspekty realizacji

3.1. Multi-headed deep RNN

Rekurencyjna sieć neuronowa różni się od sieci MLP tym, że zachowuje kontekst, tzn. poprzednie wejście sieci ma wpływ na jej aktualne wyjście. Pozwala to na uczenie jej na danych sekwencyjnych, takich jak tekst.
Aby nauczyć taką sieć, należy ją rozwinąć, tj. skopiować jej model i pospinać ze sobą tak jak na rysunku poniżej, z zachowaniem zasady, że każda kopia współdzieli swoje parametry z każdą inną.

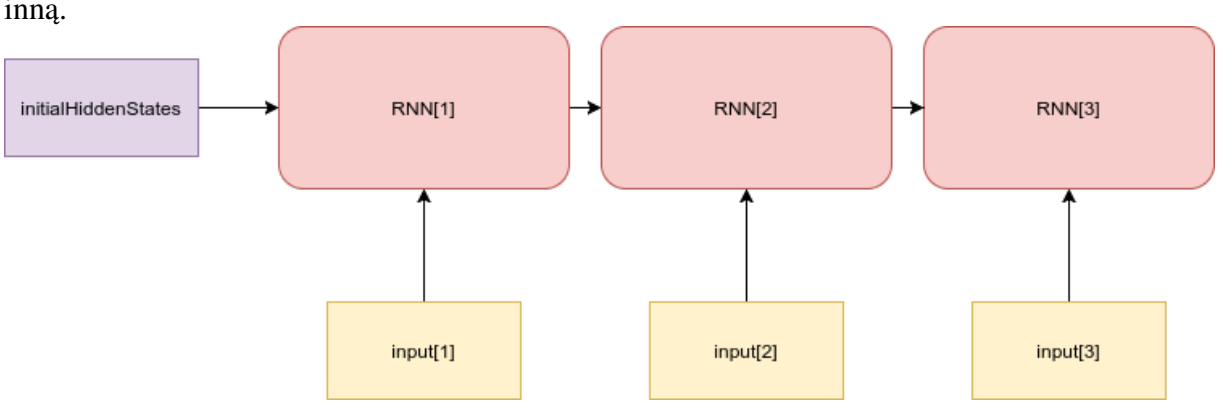

Wersja głęboka sieci rekurencyjnej polega na zwiększeniu ilości stanów ukrytych. Przykładowo na rysunku poniżej przedstawiłem sieć o dwóch stanach ukrytych x i y.

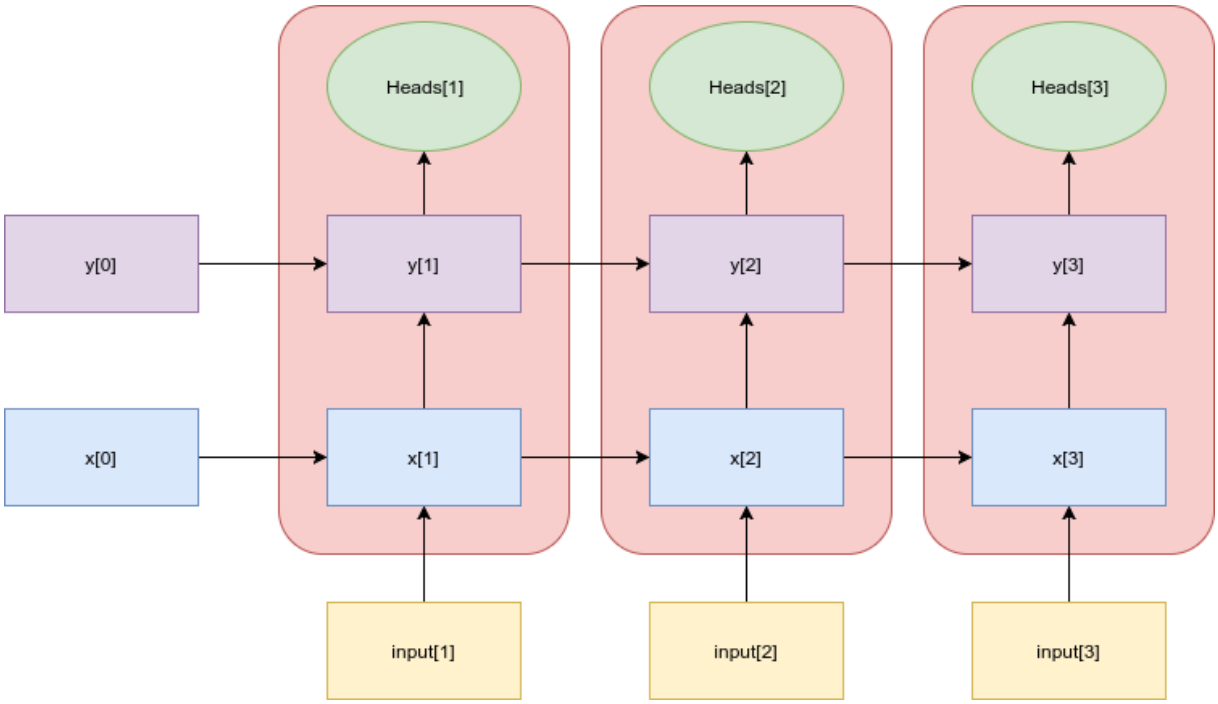

Na sam koniec warto wspomnieć, co czyni sieć wielogłową. Otóż sieć może mieć wiele wyjść współdzielących podstawowy model RNN. W tym przypadku każde wyjście (każda głowa) reprezentuje prawdopodobieństwa wystąpienia kolejnego znaku dla danego autora w reakcji na aktualny znak na wejściu.
Za całość obsługi tych sieci odpowiada moduł RNN, który jest sercem biblioteki. Dostarcza on możliwiości: tworzenia parametryzowanego modelu, rozwijania sieci, uczenia rozwiniętego modelu, zapisu oraz odczytu już wytrenowanej sieci.
W odróżnieniu od sieci Bagnalla nie używałem funkcji aktywacji ReSQRT, lecz Tanh. Algorytm uczenia w moim przypadku to normalny SGD, a nie jego optymalizacja Adagrad.

3.2. Batch danych

Aby przyśpieszyć operację uczenia sieci, należy zastosować batche danych. Jeżeli wprowadzamy na wejście sieci wektor, to otrzymujemy na wyjściu wektor, lecz równie dobrze można wprowadzić na wejście macierz złożoną z kilku wektorów i w efekcie otrzymać macierz na wyjściu. Takie podejście jest o wiele bardziej wydajne niż proste iterowanie po danych.
Za przygotowywanie batchów danych odpowiedzialny jest moduł BatchManager.

3.3. Preprocessing

Alfabet tekstu wejciowego jest zbyt duży, co w sieciach rekurencyjnych może skutkować słabą generalizacją. W tym celu stosuję różne redukcje:

- każdą wielką literę zastępuję specjalnym prefiksem oraz odpowiadającą mu małą literą
- wszystkie nawiasy sprowadzam do jednej formy
- żadkie znaki usuwam z alfabetu
- oraz inne zależne od języka (angielski, grecki, holenderski, hiszpański)

Dodatkowo wielokrotne wystąpienia danego znaku pod rząd skracane jest do pięciu wystąpień.

4. Organizacja pracy

4.1. Metodyka

Praca nad projektem przebiegała w modelu iteracyjnym. Można wyróżnić najważniejsze części każdej iteracji:

- wybranie funkcjonalności
- implementacja
- testowanie

Po zebraniu wymagań, ale przed przejściem do planowania, mogę wyróżnić dodatkową fazę - zbierania informacji, gdyż musiałem jeszcze nauczyć się języka Lua, obsługi Torcha oraz teorii działania RNN.

4.2. Postępy

W wyniku zastosowanego modelu oraz hierarchii funkcjonalności podjąłem się następujących iteracji:

1. definiowanie modelu - napisanie metody umożliwiającej utworzenie konfigurowanego parametrami modelu głębokiej sieci RNN
2. wizualizacja oraz rozwinięcie modelu - dodanie opcji eksportu modelu w postaci grafu oraz zaimplementowanie metody rozwijającej model w czasie
3. podstawowy preprocessing - przygotowanie systemu przygotowującego tekst, poprzez redukcję alfabetu i zapis w postaci binarnej (na razie tylko dla języka angielskiego)
4. trening - zaimplementowanie metody uczenia rozwiniętej sieci
5. zapis oraz testy na Prometheusie - dodanie opcji eksportu i importu sieci oraz rozpoczęcie testów na klastrze
6. wielogłowa sieć - rozwinięcie sieci do postaci wielogłowej, poprawa implementacji, wprowadzenie możliwości uczenia na tekstach wielu autorów
7. testy na Prometheusie - testowanie wielogłowych sieci
8. wprowadzenie minibatchów - implementacja batchera, która przyspieszyła naukę niemal trzykrotnie minibatchów wielkości 40
9. pozostałe języki - dodanie wsparcia dla języków: hiszpańskiego, greckiego i holenderskiego

10. opcje i kolorowanie - parsowanie argumentów lini poleceń w celu uzyskania parametrów sieci oraz kolorowanie tekstu w konsoli

11. zaimplementowanie programu testującego wydajność nauczonych sieci

12. refaktoryzacja, modularyzacja kodu oraz testowanie

5. Wyniki projektu

5.1. Osiągnięcia

W wyniku przeprowadzonych prac udało się zaimplementować bibliotekę pozwalającą na tworzenie wielogłowych, głębokich sieci neuronowych - ich struktura jest kontrolowana parametrami, trenowanie sieci na sprecjalnie przygotowanych plikach uczących, zapisywanie wytrenowanych sieci oraz testowanie ich wydajności i skuteczności.

5.2. Wyniki eksperymentów

Nawet sieci uczone krótko (nie więcej niż 5 epok) wykazywały skuteczność weryfikacji autorstwa relatywnie wysoką. Podczas testowania współczynnik weryfikacji nieznanych tekstów w języku angielskim zawierał się w przedziale 0.6-0.9 w zależności od ilości autorów i czasu treningu.

5.3. Propozycje dalszego rozwoju

Sieci definiowane przez program używają zwykłego algorytmu SGD, aby poprawić ich wydajność można by dodać pewne optymalizacje, np. za pomocą pakietu optim. Dzięki zastosowaniu batchów nauka przebiega o wiele szybciej, choć z wykorzystaniem karty graficznej i pakietów cuda lub cunn możliwe jest osiągnięcie przyspieszenia wielokrotnie większego. Można by próbować pomyśleć nad wprowadzeniem lepszych metod weryfikacji autorstwa na podstawie wyników sieci.

6. Dodatki

6.1. Spotkania z opiekunem

14.03.2017
Spotkanie w celu omówienia tematu pracy. Zostałem zapoznany ze szczegółami oraz zostały mi przedstawione dokumenty będące podstawą tej pracy, jak również zostałem poinformowany potrzebie nauczenia się języka Lua oraz obsługi frameworka Torch.

28.03.2017
Spotkanie w celu doprecyzowania szczegółów i odpowiedzenia na pytania odnośnie charakterystyki tematu. Zostały mi przedstawione dodatkowe moduły Torcha pozwalające na

rozwinięcie projektu mniejszym nakładem pracy.

23.05.2017
Spotkanie prezentujące postępy w pracach nad projektem. Zostałem poinformowany o możliwości wykorzystania klastra Prometheus do testów sieci oraz zostałem dodany do granta do dostępu do superkomputera. Uzgodniliśmy również wtedy utworzenie repozytorium w systemie GitHub w celu nadzorowania dalszych postępów prac. Projekt jest dostępny pod adresem: `https://github.com/Mantagar/Author-identification`

6.2. Spotkania z prowadzącym pracownię projektową

W VI semestrze odbyły się cztery spotkania pracowni projektowej.

1. Na pierwszym przedstawione zostały nam zasady zaliczenia przedmiotu oraz zostaliśmy poinformowani o wymaganiach odnośnie kolejnych zajęć.
2. Na drugim spotkaniu prezentowaliśmy wizję naszych prac.
3. Na trzecim prezentowaliśmy analizę ryzyka oraz studium wykonalności naszych projektów oraz wymagania funkcjonalne i niefunkcjonalne.
4. Na czwartym i ostanim spotkaniu prezentowaliśmy postępy prac nad projektami.

Materiały źródłowe

[1] Author identification task. `http://pan.webis.de/clef15/pan15-web/author-identification.html`,`http://pan.webis.de/clef14/pan14-web/author-identification.html`.

[2] Lua tutorial. `https://www.lua.org/`.

[3] Torch reference manual. `https://github.com/torch/torch7`.

[4] Torch tutorial. `http://torch.ch/docs/tutorials.html`.

[5] User manual pl-grid. `https://docs.cyfronet.pl/pages/viewpage.action?pageId=4260592`.

[6] D. Bagnall. Author identification using multi-headed recurrent neural networks. `https://arxiv.org/abs/1506.04891`.

[7] D. Bagnall. Authorship clustering using multi-headed recurrent neural networks. `https://arxiv.org/abs/1608.04485`.

[8] Y. Bengio et al. How to construct deep recurrent neural networks. `https://arxiv.org/abs/1312.6026`.

[9] A. Canziani. Torch video tutorials. `https://www.youtube.com/playlist?list=PLLHTzKZzVU9ebuL6DCclzI54MrPNFGqbW`.

[10] L. Deng and D. Yu. *Deep Learning*. Now Publishers, 2014.